Storytelling Documentation Rossmann

February 25, 2022

[63]: Image("../img/ross.png")

[63]:



Rossmann History.

As lojas da Rossmann são uma rede de farmacias localizadas na europa, principalmente na Alemanha, com aproximadamente 56,200 funcionários e com mais de 4000 lojas. A empresa foi fundada por Dirk Rossmann com a sede em Burgwedel próximo de Hanover na Alemanha. ~ Wiki.

1 Contexto de Negócio

Diretor Financeiro da Rossmann em uma reunião mensal de resultados pediu a todos os gerentes de loja uma previsão de vendas para as próximas seis semanas para futuras reformas das lojas. 1. Não vai ser utilizado o E-Commerce da Rs para a previsão de vendas. 2. O modelo de negócio das lojas da Rossmann é um Varejo, logo existem vários fatores que influenciam as vendas, desdê a qualidade física da loja (pintura, detalhes...) até marketing relacionado a loja, muitas hipóteses!

Modelo de Negócio de Farmácia A Rossmann esta presente com um E-Commerce e com lojas físicas disponível para venda de diversos items, desdê maquiagens e é claro, remédios. Sobre as lojas físicas esta caracterizado em uma rede de farmácias, que estão espalhadas por diversas partes da

Europa, Podendo assim selecionar regiões com menor risco de competidores e espalhando a marca por toda a Europa.

Oque é uma Rede de Farmácia? Basicamente, a rede começa com uma loja aberta chamada matriz, a próxima loja aberta é a filial. Existem dois tipos de rede, a cadeia associada é quando várias farmácias com proprietários diferentes se juntam e cadeia privada que começa com a empresa matriz e demais filiais e tem um proprietário geral, em outras palavras o dinheiro entra seguindo um modelo de negócio do tipo Varejo.

'Primeiras Hipóteses' - Market Size: Todas as pessoas maiores de 18 anos com preferência em pessoas mais idosas. - Marketing Channels: Rossmann E-Commerce e Lojas. - Principal Metrics: - Channel Offline: Vendas em lojas Físicas. - Recency: Compras ao longo do tempo. - Frequency: Frequencia de vendas das lojas para uma previsão mais acurada. - Market Share: Competidores Proximos.

- 1. Os consumidores mais velhos compram nas lojas físicas com mais frequencia que no E-commerce ou nos competidores ?
- 2. Qual é o Investimento em marketing em relação a lojas físicas em comparação com o E-Commerce ?
- 3. Quais são os novos produtos que fazem os clientes comprarem nas lojas Rossmann em vez das lojas concorrentes ?
- 4. Como essas lojas se comportam em termos de recebimento de novas mercadorias para vender a novos clientes ?
- 5. Os produtos vendidos tem realmente um fácil acesso?
- 6. Como são distribuidos os preços desses produtos em relação a localidade da loja física?
- 7. Como os produtos da rossmann estão sendo avaliados?
- 8. Como é o processo de compra para esses clientes?
- 9. Quantos desses clientes que compraram uma vez, vão voltar a comprar novamente?
- 10. Quanto custa um clinete novo em relação as lojas físicas?
- 11. Quais são as principais marcas parceiras da Rossmann? ...

Dataset: https://www.kaggle.com/c/rossmann-store-sales

Informações dos Dados (Retirados do site do Kaggle)

Id - an Id that represents a (Store, Date) duple within the test set **Store** - a unique Id for each store Sales - the turnover for any given day (this is what you are predicting) Customers - the number of customers on a given day **Open** - an indicator for whether the store was open: 0 = closed, 1 = open StateHoliday - indicates a state holiday. Normally all stores, with few exceptions, are closed on state holidays. Note that all schools are closed on public holidays and weekends. a = public holiday, b = Easter holiday, c = Christmas, 0 = None SchoolHoliday - indicates if the(Store, Date) was affected by the closure of public schools **StoreType** - differentiates between 4 different store models: a, b, c, d Assortment - describes an assortment level: a = basic, b = extra, c = extended CompetitionDistance - distance in meters to the nearest competitor store CompetitionOpenSince[Month/Year] - gives the approximate year and month of the time the nearest competitor was opened **Promo** - indicates whether a store is running a promo on that day **Promo2** - Promo2 is a continuing and consecutive promotion for some stores: 0 = store is not participating, 1 = store is participating **Promo2Since**[Year/Week] - describes the year and calendar week when the store started participating in Promo2 PromoInterval - describes the consecutive intervals Promo2 is started, naming the months the promotion is started anew. E.g. "Feb, May, Aug, Nov" means each round starts in February, May, August, November of any given

1.1 Documentação Resumo

Descrição Estatística Renomear as colunas para snake_case, nesse formato unitário as colunas estão em um formato mais fácil para manipulação, seleção e desenvolvimento da solução, dimensão dos dados é uma forma visual de contar a quantidade de dados para checar que os requisitos do sistema suportam tais quantidades de dados, checar os dados serve basicamente para localizar eventuais erros de consulta a bancos de dados ou até inputs que estavam sendo armazenados até então, já a parte de checagem e preenchimento de valores Na vem muito da consulta da base de dados para a coleta dos dados, eventuais inputs no sistemas ou ate mesmo erros de digitação e armazenamento desses dados, após toda essa transformação vem a parte de mudar os tipos dos dados para uma melhor compreensão e realmente manter a natureza dos dados, e por fim um resumo estatístico para analisar possíveis *Outliers* ou até inputs errados no sistema, sempre fazendo a pergunta se esse dado realmente deveria estar sendo armazenado dessa forma.

Engenharia de Features Desenvolver novas features baseadas no negócio, em hipóteses e é claro, features em relação à o tempo até alguma coisa, e features derivadas a partir do tempo e datas. Também a limpeza e seleção de features que não vão ser relevantes para o desenvolvimento da solução e features que não vão estar disponíveis na produção.

Análise Exploratória de Dados Etapa onde o objetivo é analisar profundamente os dados buscando validar hipóteses e gerar novos insight's para o negócio, nessa análise profunda outro objetivo é localizar correlações, análise das variáveis categóricas, variáveis que "separam" ou aumentam o fenômeno de vendas que é o principal objetivo desse projeto.

Preparação dos Dados Objetivo é preparar os dados para os modelos matemáticos aprenderem o comportamento e assim conseguirem generalizar para o futuro o aprendizado de dados passados, pois a maioria desses modelos não entende uma variável categóricas ou outros dão uma importância muito maior a valores altos, por exemplo comparar a distância em quilometros com a idade dos consumidores. Probelma com vazamento de dados está presente nesse projeto, logo foram feitas duas preparações e separações em treino e teste para análise.

Seleção de Variáveis Selecionar possíveis variáveis que não ajudam a expandir o conhecimento desses modelos, apenas são variáveis correlacionadas que apenas aumentam a dimensionalidade causando o fenômeno da maldição da dimensionalidade, porém não se pode confiar totalmente nesses modelos e sempre trabalhar em conjunto com o conhecimento de negócio e o conhecimento adquirido da análise exploratória dos dados. Sendo a variável promo a mais importante seguindo a importância pelo XGBoost.

Algoritimos de Ml São os modelos que irão generalizar para o futuro o aprendizado de toda essa preparação e análise dos dados, com o cross validation para recolher a melhor e verdadeira performace dos modelos. 1. Support Vector Regression (Modelo de Regressão com Kernel). 2. XGBoost (Modelo de Boosting baseado em Arvores). 3. Random Forest. 5. Neural Network One Hidden Layer n Units.

Performace do Algoritimo em Resultados Com o Algoritimo XGBoost:

2 Desafio

Previsão Acurada de cada uma das n lojas da Rossmann, onde o Diretor pode checar essas previsões no celular com a aplicação do Telegram e acessar essas previsões em um aplicativo executável em seu computador caso não estiver utilizando o celular.

```
Total de Lojas Físicas: 1115
Nos anos de: {2013, 2014, 2015}
```

2.1 0.0. Imports & Functions

```
[1]: import pickle
     import warnings
     import datetime
     import inflection
     import numpy as np
     import pandas as pd
     import seaborn as sns
     import statsmodels.api as sm
     import statsmodels.formula.api as api
     import matplotlib.gridspec as gridspec
     from random
                           import sample
     from scipy
                           import stats
     from sklearn.svm
                           import SVR
     from IPython.display import Image
     from matplotlib
                           import pyplot as plt
     from sklearn
                           import preprocessing as pp
     from sklearn.ensemble import RandomForestRegressor
     from Utils
                           import metricsAndPlots as mkk
     from xgboost
                           import XGBRegressor, plot_importance
     from tensorflow.keras import Sequential
     from tensorflow.keras.layers import Dense
     warnings.filterwarnings('ignore')
     mp = mkk()
```

2.2 0.2. Loading Data

```
[16]: df_store = pd.read_csv("../data/store.csv", low_memory=False )
df_train = pd.read_csv("../data/train.csv", low_memory=False )
```

```
df_raw = pd.merge( df_train, df_store, on="Store", how="left" )
```

3 Desenvolvimento da Solução

3.1 1.0. Statistical Description

```
[17]: df1 = df_raw.copy()
```

3.1.1 1.1. Rename Columns

```
[18]: df1.columns = [inflection.underscore( p ) for p in df1.columns.tolist()]
```

3.1.2 1.2. Data Dimension

```
[19]: print(f'Number of Rows: {df1.shape[0]}' )
print(f'Number of Columns: {df1.shape[1]}' )
```

Number of Rows: 1017209 Number of Columns: 18

3.1.3 1.3. Data Types

```
[20]: df1["date"] = pd.to_datetime( df1["date"] )
    df1.dtypes
```

```
[20]: store
                                                 int64
      day_of_week
                                                 int64
      date
                                       datetime64[ns]
                                                 int64
      sales
                                                 int64
      customers
                                                 int64
      open
      promo
                                                 int64
      state_holiday
                                                object
                                                 int64
      school_holiday
      store_type
                                                object
                                                object
      assortment
      competition_distance
                                               float64
      competition_open_since_month
                                               float64
      competition_open_since_year
                                               float64
      promo2
                                                 int64
      promo2_since_week
                                               float64
      promo2_since_year
                                               float64
      promo_interval
                                                object
      dtype: object
```

3.1.4 1.4. Check Na

```
[8]: df1.isna().sum()
[8]: store
                                            0
     day_of_week
                                            0
     date
                                            0
                                            0
     sales
     customers
                                            0
     open
                                            0
                                            0
     promo
     state_holiday
                                            0
     school_holiday
                                            0
                                            0
     store_type
     assortment
                                            0
     competition_distance
                                         2642
     competition_open_since_month
                                       323348
     competition_open_since_year
                                       323348
     promo2
     promo2_since_week
                                       508031
     promo2_since_year
                                       508031
                                       508031
     promo_interval
     dtype: int64
[9]: df1.isna().sum() / len( df1 )
[9]: store
                                       0.000000
     day_of_week
                                       0.000000
     date
                                       0.00000
     sales
                                       0.00000
     customers
                                       0.000000
                                       0.000000
     open
     promo
                                       0.000000
     state_holiday
                                       0.000000
                                       0.000000
     school_holiday
     store_type
                                       0.000000
                                       0.000000
     assortment
     competition_distance
                                       0.002597
     competition_open_since_month
                                       0.317878
     competition_open_since_year
                                       0.317878
     promo2
                                       0.000000
     promo2_since_week
                                       0.499436
     promo2_since_year
                                       0.499436
     promo_interval
                                       0.499436
     dtype: float64
```

3.1.5 1.5. Fillout Na

Fillna Assumptions (1° Cicle) - Competition Distance: If don't have close distance competition, dont have competition or competitor is too far. - Competition Open Since Month: Using the Month of Date Column. - Competition Open Since Year: Using the Year of Date Column. - Promo2 Since Week: If shop dont started promo 2 extension then 0. - Promo2 Since Year: If shop dont started promo 2 extension then 0. - Is Promo: New Column to check if current sale is in promo.

```
[21]: df1["competition distance"]
                                         = df1["competition distance"].fillna(___
      <u>→</u>200000 )
     df1["competition_open_since_month"] = df1.apply( lambda x: x["date"].month if_
       \hookrightarrowpd.isnull(x["competition_open_since_month"]) else_\(
       df1["competition_open_since_year"] = df1.apply( lambda x: x["date"].year if pd.
      →isnull( x["competition_open_since_year"] ) else_
      →x["competition_open_since_year"], axis=1 )
     df1["promo2_since_week"].fillna( 0, inplace=True )
     df1["promo2_since_year"].fillna( 0, inplace=True )
     month = {1:"Jan", 2:"Feb", 3:"Mar", 4:"Apr", 5:"May", 6:"Jun", 7:"Jul", 8:
      →"Aug", 9:"Sept", 10:"Oct", 11:"Nov", 12:"Dec", }
     df1["promo interval"].fillna( 0, inplace=True )
     df1["month map"] = df1["date"].dt.month.map( month )
     df1["is_promo"] = df1[["month_map", "promo_interval"]].apply( lambda x: 0 if_

¬x["promo_interval"] == 0 else 1 if x["month_map"] in x["promo_interval"].
       \rightarrowsplit(',') else 0, axis=1)
```

3.1.6 1.6. Change Dtypes


3.1.7 1.7. Descriptive Statistical

1.7.1. Num Attributes

```
[73]: metrics(df1, stats=True)
[73]:
                                      att
                                              min
                                                                  range
                                                                                 mean
                                                         max
                                                                 1114.0
      0
                                   store
                                              1.0
                                                      1115.0
                                                                           558.429727
      1
                             day_of_week
                                                         7.0
                                                                    6.0
                                                                             3.998341
                                              1.0
```


```
2
                                    sales
                                              0.0
                                                    41551.0
                                                               41551.0 5773.818972
       3
                                              0.0
                                                     7388.0
                                                                7388.0
                                                                         633.145946
                               customers
       4
                                              0.0
                                    open
                                                         1.0
                                                                   1.0
                                                                            0.830107
       5
                                              0.0
                                                         1.0
                                                                   1.0
                                   promo
                                                                            0.381515
       6
                          school_holiday
                                              0.0
                                                         1.0
                                                                   1.0
                                                                            0.178647
       7
                                                   200000.0
                                                              199980.0
                    competition_distance
                                             20.0
                                                                         5935.442677
       8
           competition_open_since_month
                                              1.0
                                                        12.0
                                                                            6.786849
                                                                  11.0
       9
                                           1900.0
                                                     2015.0
            competition_open_since_year
                                                                 115.0
                                                                        2010.324840
       10
                                  promo2
                                              0.0
                                                         1.0
                                                                   1.0
                                                                            0.500564
       11
                       promo2_since_week
                                              0.0
                                                        50.0
                                                                  50.0
                                                                           11.647665
       12
                       promo2_since_year
                                              0.0
                                                     2015.0
                                                                2015.0
                                                                        1007.010608
       13
                                is_promo
                                              0.0
                                                         1.0
                                                                   1.0
                                                                            0.171835
           median
                             std
                                        skew
                                                kurtosis
       0
            558.0
                      321.908493
                                  -0.000955
                                               -1.200524
       1
              4.0
                        1.997390
                                   0.001593
                                               -1.246873
       2
           5744.0
                    3849.924283
                                   0.641460
                                                1.778375
       3
            609.0
                     464.411506
                                    1.598650
                                                7.091773
       4
              1.0
                                  -1.758045
                        0.375539
                                                1.090723
       5
              0.0
                        0.485758
                                   0.487838
                                               -1.762018
       6
              0.0
                        0.383056
                                   1.677842
                                                0.815154
       7
           2330.0
                   12547.646829
                                  10.242344
                                              147.789712
       8
              7.0
                        3.311085
                                  -0.042076
                                               -1.232607
       9
           2012.0
                        5.515591
                                  -7.235657
                                              124.071304
       10
              1.0
                        0.500000
                                  -0.002255
                                               -1.999999
       11
              1.0
                       15.323921
                                   1.003390
                                               -0.498322
                                               -1.999993
       12
           2009.0
                     1005.876436
                                  -0.002251
       13
              0.0
                        0.377237
                                   1.739838
                                                1.027039
      1.7.1. Catt Attributes
[67]: pd.DataFrame(cat_att.apply(lambda x: x.unique().shape[0])[:3]).T
          state_holiday
                          store_type
                                       assortment
       0
[159]: | df_aux = df1[(df1["state holiday"] != 0) & (df1["sales"] > 0)]
       for i in zip( range(1, 4), ["state_holiday", "store_type", "assortment"] ):
           plt.subplot( 1, 3, i[0] )
           plt.tight_layout(w_pad=2.0, h_pad=2.0)
           sns.violinplot( x=i[1], y='sales', data=df_aux )
```

[67]:



3.2 2.0. Feature Engineering

3.2.1 2.1. Mind Map



3.2.2 2.2. Hypothesis List

- 2.2.1. Shop Hypothesis 1. Lojas com maior quadro de funcionários deverian vender mais.
- 2. Lojas com maior estoque deveriam vender mais.
- 3. Lojas com maior porte deveriam vender mais.
- 4. Lojas com menor porte deveriam vender menos.
- 5. Lojas com maior sortimento deveriam vender mais.
- 2.2.2. Product Hypothesis 1. Lojas que investem mais em marketing deveriam vender mais.
- 2. Lojas que expoem mais o produto nas vitrines deveriam vender mais.
- 3. Lojas que tem um preço menor deveriam vender mais.
- 4. Lojas que tem mais variedades de produtos deveriam vender mais.
- **2.2.3.** Time Hypothesis 1. Lojas que abrem em feriados natalinos deveriam vender mais.
- 2. Lojas que abrem no finla de semana deveriam vender mais.
- 3. Lojas que entram mais em feriados deveriam vender menos.
- 2.2.4. Final Hypothesis List 1. Lojas com maior sortimento deveriam vender mais.
- 2. Lojas com competidores mais próximos deveriam vender menos.
- 4. Lojas com competidores a mais tempo deveriam vender mais.
- 5. Lojas com promoções ativas a mais tempo deveriam vender mais.
- 6. Lojas com mais dias de promoção deveriam vender mais.
- 7. Lojas com mais promoções consecutivas deveriam vender mais.
- 8. Lojas abertas durante o feriado de natal deveriam vender mais.
- 9. Lojas deveriam vender mais ao longo dos anos.
- 10. Lojas deveriam vender mais no segundo semestre do ano.
- 11. Lojas deveriam vender mais depois do dia 10 de cada mês.
- 12. Lojas deveriam vender menos nos finais de semana.
- 13. Lojas deveriam vender menos nos feriados escolares.

3.2.3 2.3. Feature Engineering

[23]: df2 = df1.copy()

```
[24]: # Year
     df2['year'] = df2["date"].dt.year
     # Month
     df2['month'] = df2["date"].dt.month
     # Week of Year
     df2['week_of_year'] = df2["date"].dt.weekofyear
     # Year Week
     df2['year week'] = df2["date"].dt.strftime( '%Y-%W' )
     # Day
     df2["day"] = df2['date'].dt.day
     # Competition Since
     df2["competition_since"] = df2.apply( lambda x: datetime.datetime(__
      ⇔year=x["competition_open_since_year"],
      →month=x["competition_open_since_month"], day=1), axis=1)
     # Competition Time Month
     df2['competition_time_month'] = ((df2["date"] - df2["competition_since"] ) /__
      →30).apply( lambda x: x.days ).astype('int64')
     # Promo Since
     df2['promo_since'] = df2['promo2_since_year'].astype( str ) + '-' +__

→df2['promo2_since_week'].astype( str )
     df2['promo_since'] = df2["promo_since"].apply( lambda x: datetime.datetime.
      \rightarrowstrptime( x + '-1', '%Y-%W-%w' ) - datetime.timedelta( days=7 ) if x !=__
      \rightarrow'0-0' else x.replace('0-0', '0'))
     df2['promo_time_week'] = ((df2['date'] - df2[~pd.notnull(df2['promo_since'].str.
      →astype('int64')
     # Assortment
     df2['assortment'] = df2["assortment"].map({"a":"basic", "b":"extra", "c":
      →"extended"})
     # State Holiday
     df2['state_holiday'] = df2['state_holiday'].map({'a':'public_holiday', 'b':
```

3.3 3.0. Data Filtering

```
[25]: df3 = df2.copy()
```

3.3.1 3.1. Row Features

```
[26]: df3[(df3['open'] == 0) & (df3['sales'] > 0)]
```

[26]: Empty DataFrame

Columns: [store, day_of_week, date, sales, customers, open, promo, state_holiday, school_holiday, store_type, assortment, competition_distance, competition_open_since_month, competition_open_since_year, promo2, promo2_since_week, promo2_since_year, promo_interval, month_map, is_promo, year, month, week_of_year, year_week, day, competition_since, competition_time_month, promo_since, promo_time_week]
Index: []

[0 rows x 29 columns]

```
[27]: df3 = df3[(df3['open'] != 0) & (df3['sales'] > 0)]
```

3.3.2 3.2. Columns Selection

```
[28]: df3 = df3.drop( ['customers', 'open', 'month_map', 'promo_interval'], axis=1 )
df3 = df3.reset_index( drop=True )

df3.to_csv("../data_backup/df3.csv")
```


3.4 4.0. Exploratory Data Analysis

```
[]: df4 = df3.copy()
```

3.4.1 4.1. Univariable Analysis


4.1.1. Response Variable

```
[58]: plot_target( [df4['sales'], np.log1p( df4['sales'] )], 'Sales' );
```



4.1.2. Numerical Variable

[161]: num_att, catt_att = metrics(df4)
plot_num_att(num_att, num_att.columns.tolist())




4.1.3. Categorical Variable

```
[415]: color = ['navy', 'r', 'g', 'k']

plot_categorical( df4, color );
```


No artists with labels found to put in legend. Note that artists whose label start with an underscore are ignored when legend() is called with no argument.





3.4.2 4.2. Bivariable Analysis

H1. Lojas com maior sortimento deveriam vender mais.

• Assumindo Extra como a maior a hipótese é Falsa









Teste de Hipótese Anova.


```
[87]: anova_scipy( df4[df4['assortment'] == 'basic']['sales'], df4[df4['assortment']_
       →== 'extended']['sales'],df4[df4['assortment'] == 'extra']['sales'] )
     P-Valor: 0.0
     Estatística F: 6302.467300859967
[83]: anova_stats( df4, 'sales ~ assortment' )
[83]:
                        sum_sq
                                       df
                                                        PR(>F)
                                                           0.0
      assortment
                  1.196459e+11
                                      2.0
                                           6302.467301
      Residual
                  8.014419e+12 844335.0
                                                   NaN
                                                           NaN
```


H2. Lojas com competidores mais próximos deveriam vender menos.

• Análise do grafico responde a hipótese como Falsa











H4. Lojas com competidores a mais tempo deveriam vender mais.

• Quando mais proximo da abertura do competidor maior as vendas, logo a hipótese é Falsa







H5. Lojas com promoções ativas a mais tempo deveriam vender mais.

• Dependendo da quantidade de dias de promoções extendidas, é um prejuizo para a loja, logo a hipótese é **Falsa**

```
[417]: aux = df4[['promo_time_week', 'sales']].groupby('promo_time_week').sum().

→reset_index()

aux1 = aux[aux['promo_time_week'] < 0] # Regular Promo

aux2 = aux[aux['promo_time_week'] > 0] # Extended Promo

plt.subplot(1, 2, 1)

sns.heatmap(aux.corr(method='pearson'), annot=True);


plt.subplot(1, 2, 2)


ax = sns.regplot(aux1['promo_time_week'], aux1['sales'], color='r')

ax = sns.regplot(aux2['promo_time_week'], aux2['sales'], color='k')

progression_bar(aux1, aux2, 'sales', 'promo_time_week', 'regular_promo', 

→'extended_promo', text_dims0=230, text_dims1=3*100)
```






H6. Lojas com mais dias de promoção deveriam vender mais.


H7. Lojas com mais promoções consecutivas deveriam vender mais.

• Falsa, de acordo com os gráficos e o teste de hipóteses.

```
[494]: aux1 = df4[['promo', 'sales', 'year']].groupby(['promo', 'year']).sum().

-reset_index()
```






H8. Lojas abertas durante o feriado de natal deveriam vender mais.

• De acordo com os gráficos, nem o dado do ano de 2015 temos armazenado, poderia fazer uma

previsão para esses dados ou coletar eles, logo a hipótese é **Verdadeira** (Em relação a 2013 - 2014), pois as lojas vendem mais acada ano nos feriados de natal, mas em relação a outras variáveis não vende mais.



```
[85]: anova_scipy( df4[df4['state_holiday'] == 'christmas']['sales'], 

→df4[df4['state_holiday'] == 

→ 'easter_holiday']['sales'], df4[df4['state_holiday'] == 

→ 'public_holiday']['sales'])
```

public holiday

P-Valor: 0.01654142394072274 Estatística F: 4.120494254925124

```
[86]: anova_stats( df4, 'sales ~ state_holiday' )
```


```
[86]: sum_sq df F PR(>F)
state_holiday 3.429413e+09 3.0 118.710298 7.283351e-77
Residual 8.130635e+12 844334.0 NaN NaN
```


H9. Lojas deveriam vender mais ao longo dos anos.

• Como não temos todos os dados, apriori poderiamos dizer que realmente as lojas poderiam vender menos ao longo dos anos, mas como o ano de 2015 não esta concluido, pode ser que as vendas em 2015 aumentem, logo essa hipótese é **Verdadeira**

```
[120]: aux = df4[['sales', 'year']].groupby(['year']).sum().reset_index()
sns.heatmap( aux.corr( method='pearson' ), annot=True );
```







H11. Lojas deveriam vender mais depois do dia 10 de cada mês.

• Devido ao dobro do periodo não há uma comparação justa, logo é Verdadeira

```
[134]: | aux = df4[['day', 'sales']].groupby('day').sum().reset_index()
       aux['before_10'] = aux['day'].apply( lambda x: 'before_10' if x <= 10 else_
       aux1 = aux[['before_10', 'sales']].groupby('before_10').sum().reset_index()
       plot_bar( aux1, 'before_10', xl='sales_by_days', scatter=True,_

df_scatter_x=aux['day'] , df_scatter_y=aux['sales'] )
            4.0
            3.5
                                                    2.2
            3.0
                                                    2.0
            2.5
           2.0
                                                   1.8
            1.5
                                                   1.6
            1.0
                                                   1.4
            0.5
                                                    1.2
```

H12. Lojas deveriam vender menos nos finais de semana.

before_10

• Dado os gráficos, as lojas realmente vendem menos.


sales_by_days


after_10

0

5


20





H13. Lojas deveriam vender menos nos feriados escolares.

• Em comparação com os demais meses e lembrando que não esta fechado o dataset, logo essa hipótese é **falsa**.




3.4.3 4.3. Multivariable Analysis

```
[316]: num_att, catt_att = mp.metrics( df4 )
```

4.3.1. Numerical Attributes

```
[312]: plt.rcParams['figure.figsize'] = [20, 18] sns.heatmap( num_att.corr( method='pearson' ), annot=True );
```



4.3.2. Categorical Attributes

[380]: sns.heatmap(d, annot=True);



3.5 5.0. Data Preparation

```
[228]: df5 = df3.copy()
```

3.5.1 5.1. Normalization

```
[156]: cols = num_att.columns.tolist()

# Hipótese Nula (Ho): As Distribuições vem de uma pop normal.

# Hipótese Alte (Ha): As distribuições não vem de uma pop normal.

# alpha → 0.05

fig, ax = plt.subplots(6, 3, figsize=(15, 30))
plt.tight_layout(w_pad=3.0, h_pad=3.0)
for i in range(len(cols)):
    ax = ax.flatten()
    print("T Stats: {:.4f} for {}".format(stats.kstest(df5[cols[i]], 'norm'

→)[1], cols[i]))
    stats.probplot(df5[cols[i]], plot=ax[i])
```

T Stats: 0.0000 for store
T Stats: 0.0000 for day_of_week
T Stats: 0.0000 for sales
T Stats: 0.0000 for promo
T Stats: 0.0000 for school_holiday

```
T Stats: 0.0000 for competition_distance
```

T Stats: 0.0000 for promo2

T Stats: 0.0000 for promo2_since_week
T Stats: 0.0000 for promo2_since_year

T Stats: 0.0000 for is_promo T Stats: 0.0000 for year T Stats: 0.0000 for month


T Stats: 0.0000 for week_of_year

T Stats: 0.0000 for day

T Stats: 0.0000 for competition_time_month

T Stats: 0.0000 for promo_time_week

T Stats: 0.0000 for competition_open_since_month
T Stats: 0.0000 for competition_open_since_year



3.5.2 5.2. Rescaling

3.5.3 5.3. Transformation

5.3.1. Encoding

5.3.2. Response Transformation

```
[243]: df5['sales'] = np.log1p(df5['sales'])
```

5.3.3. Nature Transformation

```
[244]: # month

df5['month_sin'] = df5['month'].apply( lambda x: np.sin( x * ( 2. * np.pi / 12_\( \to \) ) ) )

df5['month_cos'] = df5['month'].apply( lambda x: np.cos( x * ( 2. * np.pi / 12_\( \to \) ) )
```

```
df5['day_sin'] = df5['day'].apply(lambda x: np.sin(x * (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. * np.pi / Lambda x) + (2. * (2. *
                 →30 ) ) )
               df5['day cos'] = df5['day'].apply(lambda x: np.cos(x * (2. * (2. * np.pi / 1.1))]
                 →30 ) ) )
               # day_of_week
               df5['day of week sin'] = df5['day of week'].apply( lambda x: np.sin( x * ( 2. *_
                 →np.pi / 7 ) ) )
               df5['day_of_week_cos'] = df5['day_of_week'].apply(lambda x: np.cos(x * (2. *_
                 →np.pi / 7 ) ) )
               # week_of_year
               df5['week_of_year_sin'] = df5['week_of_year'].apply(lambda x: np.sin(x * (2.__
                 →* np.pi / 52 ) ) )
               df5['week_of_year_cos'] = df5['week_of_year'].apply( lambda x: np.cos( x * ( 2.__
                 →* np.pi / 52 ) ) )
[246]: df5.head()
[246]:
                      store
                                     day_of_week
                                                                             date
                                                                                                 sales
                                                                                                                promo
                                                                                                                               state_holiday \
                              1
                                                           5 2015-07-31 8.568646
                                                                                                                          1
                                                                                                                                           0.998922
               1
                              2
                                                            5 2015-07-31 8.710290
                                                                                                                          1
                                                                                                                                            0.998922
               2
                               3
                                                           5 2015-07-31 9.025816
                                                                                                                          1
                                                                                                                                           0.998922
               3
                              4
                                                           5 2015-07-31 9.546527
                                                                                                                          1
                                                                                                                                            0.998922
                                                           5 2015-07-31 8.481151
                                                                                                                          1
                                                                                                                                           0.998922
                     school_holiday store_type assortment competition_distance ...
               0
                                                  1
                                                              0.133795
                                                                                        0.526892
                                                                                                                                       -0.170968
                                                  1
                                                              0.541302
                                                                                        0.526892
                                                                                                                                       -0.283871 ...
               1
               2
                                                  1
                                                             0.541302
                                                                                        0.526892
                                                                                                                                         1.903226
               3
                                                  1
                                                              0.133795
                                                                                        0.463386
                                                                                                                                       -0.275806
                                                              0.541302
                                                                                                                                         4.448387 ...
                                                  1
                                                                                        0.526892
                                       promo_since promo_time_week month_sin month_cos
                                                                                                                                                             day_sin \
                                                                                                                                  -0.866025 0.406737
               0
                                                                                    0.287016
                                                                                                                     -0.5
               1
                     2010-03-22 00:00:00
                                                                                    0.922551
                                                                                                                     -0.5 -0.866025 0.406737
               2
                     2011-03-28 00:00:00
                                                                                    0.801822
                                                                                                                     -0.5 -0.866025
                                                                                                                                                          0.406737
                                                                                                                     -0.5 -0.866025 0.406737
               3
                                                              0
                                                                                    0.287016
               4
                                                              0
                                                                                    0.287016
                                                                                                                     -0.5 -0.866025 0.406737
                        day_cos day_of_week_sin day_of_week_cos week_of_year_sin \
               0 0.913545
                                                         -0.974928
                                                                                               -0.222521
                                                                                                                                       -0.568065
               1 0.913545
                                                         -0.974928
                                                                                               -0.222521
                                                                                                                                       -0.568065
               2 0.913545
                                                         -0.974928
                                                                                               -0.222521
                                                                                                                                       -0.568065
               3 0.913545
                                                         -0.974928
                                                                                               -0.222521
                                                                                                                                       -0.568065
               4 0.913545
                                                         -0.974928
                                                                                               -0.222521
                                                                                                                                       -0.568065
```

day

```
0 -0.822984

1 -0.822984

2 -0.822984

3 -0.822984

4 -0.822984

[5 rows x 33 columns]

[247]: df5.to_csv("../data_backup/df5.csv")
```

3.6 6.0. Feature Selection

week_of_year_cos

```
[3]: df6 = pd.read_csv("../data_backup/df5.csv")
df6['date'] = pd.to_datetime( df6['date'] )

cols = ['Unnamed: 0', 'week_of_year', 'day', 'month', 'promo_since',

→'competition_since', 'day_of_week', 'year_week']
df6 = df6.drop( columns=cols, axis=1 )
```

3.6.1 6.1. Split Into Train and Test

- After 06-19 Test Dataset
- Before 06-16 Train Dataset

```
[4]: X_train = df6[df6['date'] < df6['date'].max() - datetime.timedelta( days=42 )]
y_train = X_train['sales']

X_test = df6[df6['date'] >= df6['date'].max() - datetime.timedelta( days=42 )]
y_test = X_test['sales']

print(f"Train Min Date: {X_train['date'].min()}")
print(f"Test Min Date: {X_test['date'].min()}")

print(f"\nTrain Max Date: {X_train['date'].max()}")
print(f"Test Max Date: {X_test['date'].max()}")
```

Train Min Date: 2013-01-01 00:00:00 Test Min Date: 2015-06-19 00:00:00

Train Max Date: 2015-06-18 00:00:00 Test Max Date: 2015-07-31 00:00:00


3.6.2 6.2. XGBoost Feature Importance

```
[131]: X_train_xg = X_train.drop( columns=['sales', 'date'], axis=1 ).values
    y_train_xg = y_train.values

xg = XGBRegressor( n_jobs=-1 ).fit( X_train_xg, y_train_xg )

importances = {}
for i in range( 0, 24 ):
    importances[X_train.drop( columns=['date', 'sales'], axis=1 ).columns[i]] =___
    xg.feature_importances_[i]
```

```
[132]: fig, ax = plt.subplots( figsize=(15, 8))
ax.bar( importances.keys(), importances.values(), **mp.args_b(edgecolor='k') )
plt.xticks( rotation=80 );
```



```
[119]: df3['state_holiday'].value_counts()
```

[119]: regular_day 595478
 public_holiday 483
 easter_holiday 98

```
christmas 71
Name: state_holiday, dtype: int64
```

3.6.3 6.3. Boruta Feature Selection

3.6.4 6.4. Manual Feature Selection

3.7 7.0. Machine Learning Models

3.7.1 7.1. Average Model

[203]: Model Name MAE MAPE RMSE 0 Avg Model 1354.800353 0.2064 1835.135542

3.7.2 7.2. SVR.

[204]: Model Name MAE MAPE RMSE 0 SVR Model 5786.217815 0.794773 6537.894802

3.7.3 7.3. Random Forest Regression

```
[205]: # Definition
rf = RandomForestRegressor( n_jobs=-1, random_state=42 ).fit( x_train_, y_train_\)
# Predict
yhat_rf = rf.predict( x_test_ )

# performace
rf_result = mp.ml_error( 'Random Forest Model', np.expm1( y_test ), np.expm1(\)
\[
\top \]
yhat_rf ) )
```

```
rf_result
[205]:
                  Model Name
                                      MAE
                                               MAPE
                                                            RMSE
      O Random Forest Model
                              682.975548 0.100779 1013.700116
      3.7.4 7.4. XGBoost Regression
[82]: # Definition
       #xq = XGBReqressor( n jobs=-1, random state=42 ).fit( x train , y train )
       # Predict
      yhat_xg = xg.predict( x_test_ )
      # Performace
      xg_result = ml_error2( 'XGBoost Model', np.expm1( y_test ), np.expm1( yhat_xg )_
       →)
      xg_result
[82]:
            Model Name
                                      MAPE
                                                    RMSE
                             MAE
      0 XGBoost Model 0.131237 0.131237 1277.698002
      3.7.5 7.5. Model Performace
[208]: model_performace_0 = pd.concat( [xg_result, rf_result, svr_result, ____
       →base_result], axis=0 ).sort_values( 'RMSE' ).reset_index( drop=True )
      model_performace_0
[208]:
                                                             RMSE
                  Model Name
                                      MAE
                                                MAPE
        Random Forest Model
                                                      1013.700116
                               682.975548 0.100779
      1
               XGBoost Model
                               888.718076 0.131237
                                                      1277.698002
      2
                   Avg Model 1354.800353 0.206400
                                                     1835.135542
      3
                   SVR Model
                              5786.217815 0.794773 6537.894802
      3.8 7.x. Data Preparation After Split
[11]: \#df\%x = df3.copy()
      df7x = pd.read_csv("../data_backup/df3.csv")
      df7x = df7x.drop( columns=['Unnamed: 0'], axis=1 )
```

df7x['date'] = pd.to_datetime(df7x['date'])

3.8.1 7.1. Split Dataset

Train Min Date: 2013-01-01 00:00:00 Test Min Date: 2015-06-19 00:00:00

Train Max Date: 2015-06-18 00:00:00 Test Max Date: 2015-07-31 00:00:00

3.8.2 7.2. Data Preparation

```
[13]: rs = pp.RobustScaler()
mms = pp.MinMaxScaler()

y_test = np.log1p( y_test )
y_train = np.log1p( y_train )

X_train, X_test = mp.train_test_prep( X_train, X_test )
```

3.8.3 7.3. Machine Learning Models

```
[14]: x_train = X_train[cols_selected]
x_test = X_test[cols_selected]
```

7.3.1. Average Model

```
# Performace
       base_result = mp.ml_error( 'Avg Model', np.expm1( y_test ), np.expm1( yhat_base_
       base_result
[144]: Model Name
                            MAE
                                   MAPE
                                                 RMSE
       0 Avg Model 1354.800353 0.2064 1835.135542
      7.3.2. SVR
 [49]: # Definition
       svr = SVR(max_iter=100).fit( x_train, y_train )
       # Predict
       yhat_svr = svr.predict( x_test )
       # Performace
       svr_result = mp.ml_error( 'SVR Model', np.expm1( y_test ), np.expm1( yhat_svr )__
       →)
       svr result
 [49]: Model Name
                            MAE
                                     MAPE
       0 SVR Model 5786.217647 0.794773 6537.894648
      7.3.3. Random Forest Regression
[186]: # fit
       rf = RandomForestRegressor( n_jobs=-1, random_state=42 ).fit( x_train, y_train )
       # predict
       yhat_rf = rf.predict( x_test )
       # performace
       rf_result = mp.ml_error( 'Random Forest Model', np.expm1( y_test ), np.expm1( u
       →yhat_rf ) )
      rf result
[186]:
                  Model Name
                                              MAPE
                                     MAE
                                                           RMSE
      0 Random Forest Model 912.069229 0.125143 1299.120407
      7.3.4. XGBoost Regression
[185]: # Definition
       xg = XGBRegressor( n_jobs=-1, random_state=42 ).fit( x_train, y_train )
       # Predict
       yhat_xg = xg.predict( x_test )
```

```
# Performace
      xg result = mp.ml_error( 'XGBoost Model', np.expm1( y_test ), np.expm1( yhat_xg_
       →) )
      xg_result
[185]:
            Model Name
                                MAE
                                         MAPE
                                                      RMSE
      0 XGBoost Model 1490.819553 0.186662 2081.622564
      3.8.4 7.4. Model Results
[197]: pd.concat([base_result, svr_result, rf_result, xg_result], axis=0).
       →reset_index( drop=True ).sort_values( 'RMSE' )
                  Model Name
                                                            RMSE
[197]:
                                      MAE
                                               MAPE
      2 Random Forest Model
                                                     1299.120407
                               912.069229 0.125143
                   Avg Model 1339.842213 0.206209 1740.751135
      3
               XGBoost Model 1490.819553 0.186662 2081.622564
                   SVR Model 6478.753549 0.813506 7191.242927
[209]: model_performace_0
[209]:
                  Model Name
                                                            RMSE
                                      MAE
                                               MAPE
      O Random Forest Model
                               682.975548 0.100779
                                                     1013.700116
               XGBoost Model
      1
                               888.718076 0.131237
                                                     1277.698002
      2
                   Avg Model 1354.800353 0.206400
                                                     1835.135542
                   SVR Model 5786.217815 0.794773 6537.894802
[199]: x train.to csv('../data backup/x train after.csv')
      x_test.to_csv('../data_backup/x_test_after.csv')
      3.8.5 7.5. Cross Validation
[114]: # Feature Selection + Store and Sales
      x_training = X_train[ cols_full ]
 [9]: a0 = mp.cross_val( x_training, 4, 'SVR Model', SVR( max_iter=4 ) )
      a1 = mp.cross_val( x_training, 4, 'Random Forest Model', RandomForestRegressor(_
       →n_jobs=-1, random_state=42 ) )
      a2 = mp.cross_val( x_training, 4, 'XGBoost Model', XGBRegressor( n_jobs=-1,_
       →random_state=42 ) )
[10]: models_cross_val = pd.concat( [a0, a1, a2], axis=0 ).reset_index( drop=True )
      models_cross_val
```

```
[10]: Model Name MAE Cv MAPE Cv \
0 SVR Model 5780.784 +/- 338.408 0.779 +/- 0.009
1 Random Forest Model 792.646 +/- 170.059 0.115 +/- 0.023
2 XGBoost Model 990.471 +/- 94.369 0.142 +/- 0.007

RMSE Cv
0 6513.706 +/- 394.442
1 1175.622 +/- 241.843
2 1406.819 +/- 145.715
```

3.9 8.0. Hyperparameter Fine Tuning

```
[87]: #from sklearn.model_selection import GridSearchCV
    # Param Info: https://xgboost.readthedocs.io/en/stable/parameter.html

params = {
        'n_estimators': [2500, 2900, 3000, 3100, 3200, 3500],
        'eta': [.02, .03, .033, .035],
        'gamma': [1., 1.5],
        'max_depth': [5, 6, 7],
        'subsample': [.6, .7, .8, .9],
        'min_child_weight': [3, 4, 5, 6, 7],
        'colsample_bytree': [.5, .7, .9, 1.]
}
```

```
[19]: # for i in range(50):
             hp = \{k: sample(v, 1) \text{ for } k, v \text{ in params.} items()\}
             print(hp, file=open('parameters.txt', 'a'))
             # Definition
      #
      #
             xg = XGBRegressor(n_jobs = -1,
      #
                                 n_estimators = hp['n_estimators'][0],
      #
                                 eta = hp['eta'][0],
                                 gamma = hp['gamma'][0],
      #
                                 max depth = hp['max depth'][0],
      #
                                 subsample = hp['subsample'][0],
      #
                                 min_child_weight = hp['min_child_weight'][0],
                                 colsample_bytree = hp['colsample_bytree'][0])
      #
      #
             # Performace
             xg_result = mp.cross_val( x_training, 2, 'XGBoost Model', xg )
             print(f'' \{ xq result['RMSE Cv'].tolist()[0] \} \n'', file=open('parameters.
       \hookrightarrow txt', 'a') )
```

3.9.1 8.1. Final Model

```
[88]: param_tunned = {
         'n_estimators': 3500,
         'eta': .035,
         'gamma': 1,
         'max_depth': 6,
         'subsample': .7,
         'min_child_weight': 7,
         'colsample_bytree': 1
}
```

3.9.2 8.2. Model Performace (Prepare -> Split)

```
[90]: xg_tnn = XGBRegressor( n_jobs = -1,
                             n_estimators = param_tunned['n_estimators'],
                             eta
                                   = param_tunned['eta'],
                             gamma = param_tunned['gamma'],
                             max_depth = param_tunned['max_depth'],
                             subsample = param_tunned['subsample'],
                             min_child_weight = param_tunned['min_child_weight'],
                             colsample_bytree = param_tunned['colsample_bytree']).
       →fit(x_train, y_train)
      # Predict
      yhat = xg_tnn.predict( x_test )
      # Performace
      xg_result_t = mp.ml_error( "XGBoost Tunned", np.expm1( y_test ), np.expm1( yhat_
      →) )
      xg_result_t
```

```
[90]: Model Name MAE MAPE RMSE
0 XGBoost Tunned 1251.518232 0.170826 1768.033845
```

```
[16]: y_test.head().tolist()
```

```
[16]: [8.568646473005153,
8.71028982137815,
9.025816391627028,
9.54652685348758,
8.481151420068972]
```

```
[17]: yhat[:5].tolist()
```


[17]: [8.429130554199219, 8.647663116455078,

```
9.102029800415039,
        8.884071350097656,
        8.493669509887695]
 [26]: print(f'Diferença entre o Máximo Valor: {np.expm1( y_test.max() ) - np.expm1(__
        \rightarrowyhat.max()):.2f}')
      Diferença entre o Máximo Valor: 14998.21
 [34]: print(f'MPE: {mean_percentage_error( y_test, yhat ):.5f}')
      MPE: 0.00113
[103]: # Save best model on Pickle
       pickle.dump(xg_tnn, open("model_xgb_t.pkl", "wb"))
      3.9.3 8.3. Model Performace (Split -> Prepare)
[116]: xg_tnn = XGBRegressor( n_jobs = -1,
                              n_estimators = param_tunned['n_estimators'],
                                    = param tunned['eta'],
                              gamma = param tunned['gamma'],
                              max_depth = param_tunned['max_depth'],
                              subsample = param_tunned['subsample'],
                              min_child_weight = param_tunned['min_child_weight'],
                              colsample_bytree = param_tunned['colsample_bytree']).
        →fit( x_train_, y_train )
       # Predict
       yhat = xg_tnn.predict( x_test_ )
       # Performace
       xg_result_t = mp.ml_error( "XGBoost Tunned", np.expm1( y_test ), np.expm1( yhatu
       →))
       xg_result_t
[116]:
              Model Name
                                 MAE
                                          MAPE
                                                       RMSE
       0 XGBoost Tunned 711.385696 0.103529 1032.75967
[117]: y_test.head().tolist()
[117]: [8.568646473005153,
        8.71028982137815,
        9.025816391627028,
        9.54652685348758,
        8.481151420068972]
```

```
[118]: yhat[:5].tolist()
[118]: [8.602458953857422,
                    8.686539649963379,
                    9.136541366577148,
                    9.300227165222168,
                    8.644275665283203]
  [18]: pickle.dump(xg_tnn, open("model_xgb_t2.pkl", "wb"))
                3.9.4 8.4. NN Regressor
  [15]: # NN Dataset Preparation
                  # Comment Below -----
                  \# x_test['promo2_since_week'] = mms.fit_transform(_{\sqcup}
                   \rightarrow x_test[['promo2_since_week']].values)
                  # x_test['promo2_since_week'] = mms.fit_transform(__
                   \rightarrow x_test[['promo2_since_week']].values)
                  # x train['promo2 since year'] = mms.fit transform(
                   \rightarrow x_train[['promo2_since_year']].values)
                  # x_train['promo2_since_year'] = mms.fit_transform(__
                   \rightarrow x_train[['promo2_since_year']].values)
                  y_test_n = np.array( y_test ).reshape( -1, 1 )
                  y_train_n = np.array( y_train ).reshape(-1, 1 )
                  x_{test_n} = x_{test.values}
                  x_t = x_t 
  [33]: # Model Definition
                  model = Sequential()
                  model.add( Dense( 25, input_dim=20, activation='relu' ) )
                  model.add( Dense( 1, activation='linear') )
                  # Model Compile
                  model.compile( loss='mean_absolute_error', optimizer='adam', metrics=['mse'] )__
                   →# Test RMSE for metric ***
                  # Model Training
                  history = model.fit( x_train_n, y_train_n, validation_data=(x_test_n,_
                    \rightarrowy_test_n), epochs=50)
                  # Model Validation
                  _, train_mse = model.evaluate( x_train_n, y_train_n )
                  _, test_mse = model.evaluate( x_test_n, y_test_n )
```

```
# Model Performace
yhat_nn = model.predict( x_test_n )
yhat_nn = [p[0] for p in yhat_nn]
```

```
[17]: plt.plot( history.history['loss'], label='train', color='k' )
   plt.plot( history.history['val_loss'], label='test', color='r' )
   plt.legend();
```



```
[19]: mp.ml_error( "Neural Network Regressor", np.expm1( [p[0] for p in y_test_n] ), □ → np.expm1( yhat_nn ) )
```

[19]: Model Name MAE MAPE RMSE 0 Neural Network Regressor 1913.687997 0.282804 2787.561813

```
[34]: # Weights
model.save_weights( 'model_nn.h5' )

# Json Model File
model_jns = model.to_json()
with open('model_nn.json', 'w') as js_m:
    js_m.write( model_jns )
js_m.close()
```

3.10 9.0. Bussiness Model Performace


```
[40]: df9 = X_test.copy()
df9['prediction'] = np.expm1( yhat )
```

3.10.1 9.1. Bussiness Performace

```
[272]: df92[df92['MAPE'] > 0.55]
```

```
[272]: store prediction worst_scenario best_scenario MAE MAPE 712 713 502075.91 497508.61 506643.2 4567.294948 0.557384 814 815 359472.34 356110.39 362834.3 3361.955593 0.555540
```

Shops harder to forecast sales: - Store 713 with MAPE: 0.557 - Store 815 with MAPE: 0.555



3.10.2 9.2. Total Performace

```
[273]: Scenario Total Sales
0 Predictions R$ 276,712,777.60
1 Worst Scenario R$ 275,455,320.37
2 Best Scenario R$ 277,970,234.33
```

3.10.3 9.3. ML Performace

```
[274]: df9['error'] = df9['sales'] - df9['prediction']
df9['error_rate'] = df9['prediction'] / df9['sales']


[353]: df9['error_nn'] = df9['sales'] - np.expm1(yhat_nn)
df9['error_rate_nn'] = np.expm1(yhat_nn) / df9['sales']
```

9.3.1. XGBoost Performace


```
[329]: plt.subplot(2, 2, 1)
mp.plot_pred_sales(df9['date'], df9['sales'], df9['prediction'])
plt.subplot(2, 2, 2)
```

```
mp.plot_error_rate( df9['date'], df9['error_rate'] )
plt.subplot( 2, 2, 3 )
plt.hist( df9['error'], **mp.args(bins=100) )

plt.subplot( 2, 2, 4 )
sns.scatterplot( df9['prediction'], df9['error'], color='r' );
```



```
9.3.2. Neural Network Performace
[365]: plot_pred_sales( df9['date'], df9['sales'], np.expm1( yhat_nn ) )
```



4 Conclusão e Demonstração


[33]: Image('Img1.png')

[33]:



```
[36]: Image( 'img2.jpg' )
```

[36]:



5 Próximos Passos

- 0. Encinar o Diretor a Utilizar a Aplicação.
- 1. Entender melhor o negócio para criar novas Features.
- 2. Utilizar outras técnicas de preparação das Features.
- 3. Tunar melhor os Modelos de ML.
- 4. Desenvolver o App Executável.